Tabela Hash Estrutura de Dados Avançada — QXD0015



Prof. Atílio Gomes Luiz gomes.atilio@ufc.br

Universidade Federal do Ceará

 1° semestre/2024



Contexto: Temos um conjunto de objetos com chaves associadas e possivelmente muitos outros dados. Precisamos realizar buscas de forma muito rápida por esses objetos a partir dos valores das chaves.



Contexto: Temos um conjunto de objetos com chaves associadas e possivelmente muitos outros dados. Precisamos realizar buscas de forma muito rápida por esses objetos a partir dos valores das chaves.

 Tipos abstratos de dados que fornecem apenas as operações de inserção, busca e remoção são chamados de dicionários ou mapas.



 Aplicação: Queremos carregar um dicionário da língua portuguesa na memória do computador.



- Aplicação: Queremos carregar um dicionário da língua portuguesa na memória do computador.
 - o Operações de inserção e busca serão frequentemente realizadas.



- Aplicação: Queremos carregar um dicionário da língua portuguesa na memória do computador.
 - o Operações de inserção e busca serão frequentemente realizadas.
 - Operações de remoção podem vir a ser realizadas e gostaríamos que fossem eficientes.



Cada entrada do dicionário é composta por um par (verbete, descrição).

• paralelepípedo: Hexaedro cujas faces, opostas e paralelas entre si, são paralelogramos.



Cada entrada do dicionário é composta por um par (verbete, descrição).

• paralelepípedo: Hexaedro cujas faces, opostas e paralelas entre si, são paralelogramos.

Primeiras opções:

ullet Vetor não ordenado - busca/remoção em O(n)



Cada entrada do dicionário é composta por um par (verbete, descrição).

• paralelepípedo: Hexaedro cujas faces, opostas e paralelas entre si, são paralelogramos.

- ullet Vetor não ordenado busca/remoção em O(n)
 - \circ inserir uma nova palavra leva O(1)



Cada entrada do dicionário é composta por um par (verbete, descrição).

• paralelepípedo: Hexaedro cujas faces, opostas e paralelas entre si, são paralelogramos.

- ullet Vetor não ordenado busca/remoção em O(n)
 - \circ inserir uma nova palavra leva O(1)
- Vetor ordenado busca em $O(\lg n)$



Cada entrada do dicionário é composta por um par (verbete, descrição).

• paralelepípedo: Hexaedro cujas faces, opostas e paralelas entre si, são paralelogramos.

- Vetor não ordenado busca/remoção em O(n)
 - \circ inserir uma nova palavra leva O(1)
- Vetor ordenado busca em $O(\lg n)$
 - \circ inserir/remover uma nova palavra leva O(n)



Cada entrada do dicionário é composta por um par (verbete, descrição).

• paralelepípedo: Hexaedro cujas faces, opostas e paralelas entre si, são paralelogramos.

- Vetor não ordenado busca/remoção em O(n)
 - \circ inserir uma nova palavra leva O(1)
- Vetor ordenado busca em $O(\lg n)$
 - \circ inserir/remover uma nova palavra leva O(n)
- Árvore balanceada busca/inserção/remoção em $O(\lg n)$



Cada entrada do dicionário é composta por um par (verbete, descrição).

• paralelepípedo: Hexaedro cujas faces, opostas e paralelas entre si, são paralelogramos.

Primeiras opções:

- Vetor não ordenado busca/remoção em O(n)
 - \circ inserir uma nova palavra leva O(1)
- Vetor ordenado busca em $O(\lg n)$
 - \circ inserir/remover uma nova palavra leva O(n)
- Árvore balanceada busca/inserção/remoção em $O(\lg n)$

Vamos ver outras possibilidades



Caso Simples: Tabela de acesso direto

Tabela de acesso direto



- Suponha que uma aplicação precisa de uma estrutura de dados na qual cada elemento tem uma chave com valor no conjunto $U=\{0,1,\ldots,m-1\}\text{, em que }m\text{ não \'e muito grande}.$
 - o Supomos que não existem chaves repetidas.

Tabela de acesso direto



- Suponha que uma aplicação precisa de uma estrutura de dados na qual cada elemento tem uma chave com valor no conjunto $U=\{0,1,\ldots,m-1\}$, em que m não é muito grande.
 - Supomos que não existem chaves repetidas.
- Podemos representar essa estrutura como um vetor T[0..m-1] em que cada posição corresponde a uma chave do conjunto U.

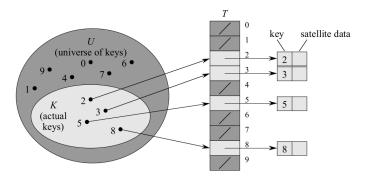


Tabela de acesso direto — Limitações



- Se o universo de possíveis chaves U for grande, então armazenar o vetor T de tamanho |U| pode ser impraticável.
 - A memória é limitada.

Tabela de acesso direto — Limitações



- Se o universo de possíveis chaves U for grande, então armazenar o vetor T de tamanho |U| pode ser impraticável.
 - A memória é limitada.

- ullet O número de chaves armazenadas pode ser muito pequeno quando comparado ao tamanho do conjunto U.
 - Espaço será desperdiçado.

Tabela de acesso direto — Limitações



- Se o universo de possíveis chaves U for grande, então armazenar o vetor T de tamanho |U| pode ser impraticável.
 - A memória é limitada.

- ullet O número de chaves armazenadas pode ser muito pequeno quando comparado ao tamanho do conjunto U.
 - Espaço será desperdiçado.
- Quando o conjunto K de chaves é muito pequeno em relação ao universo U, gostaríamos de poder armazenar as chaves em uma tabela de tamanho $\Theta(|K|)$ e ao mesmo tempo manter o benefício de realizar busca, inserção e remoção em tempo O(1).



Tabela Hash (Tabela de dispersão)



 Estrutura de dados onde as posições dos objetos armazenados são calculadas através de uma função que visa distribuir os elementos aleatoriamente ao longo de um vetor.



 Estrutura de dados onde as posições dos objetos armazenados são calculadas através de uma função que visa distribuir os elementos aleatoriamente ao longo de um vetor.



- Estrutura de dados onde as posições dos objetos armazenados são calculadas através de uma função que visa distribuir os elementos aleatoriamente ao longo de um vetor.
- ullet Tempo médio para inserção, busca e remoção: O(1)



- Estrutura de dados onde as posições dos objetos armazenados são calculadas através de uma função que visa distribuir os elementos aleatoriamente ao longo de um vetor.
- Tempo médio para inserção, busca e remoção: O(1)
- Tempo O(n) no pior caso.



- Estrutura de dados onde as posições dos objetos armazenados são calculadas através de uma função que visa distribuir os elementos aleatoriamente ao longo de um vetor.
- Tempo médio para inserção, busca e remoção: O(1)
- Tempo O(n) no pior caso.



- Estrutura de dados onde as posições dos objetos armazenados são calculadas através de uma função que visa distribuir os elementos aleatoriamente ao longo de um vetor.
- Tempo médio para inserção, busca e remoção: O(1)
- Tempo O(n) no pior caso.
- Usada em situações onde precisa-se apenas de operações de inserir, buscar e remover. Não se pode fazer caminhamento ordenado.

Componentes de uma tabela de dispersão



(1) Função de hashing

- As chaves nem sempre s\(\tilde{a}\) o valores num\(\tilde{r}\) icos. Por exemplo, as chaves podem consistir em nomes de pessoas.
 - \circ Solução: criar uma função de hashing para mapear cada chave em uma posição i do vetor T[0..m-1], com $0 \le i \le m-1$.

Componentes de uma tabela de dispersão



(1) Função de hashing

- As chaves nem sempre s\(\tilde{a}\) o valores num\(\tilde{e}\)ricos. Por exemplo, as chaves podem consistir em nomes de pessoas.
 - o Solução: criar uma função de hashing para mapear cada chave em uma posição i do vetor T[0..m-1], com $0 \le i \le m-1$.

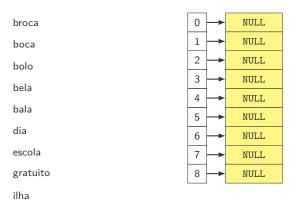
(2) Tratamento de colisão

- Duas chaves podem ser mapeadas no mesmo slot.
- Neste caso, teremos uma Colisão: duas ou mais chaves são mapeadas para a mesma posição da tabela.
- Devemos tratar uma colisão quando ela ocorrer.



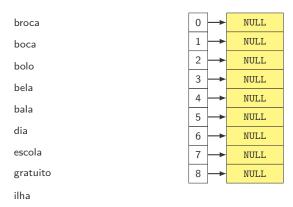
Tratamento de colisão por encadeamento exterior





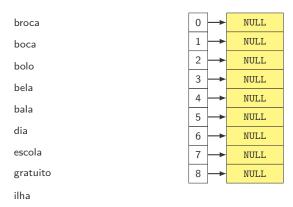
Ideia:





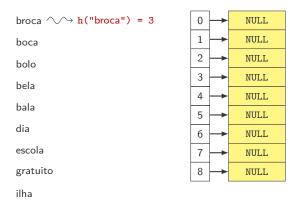
Ideia:





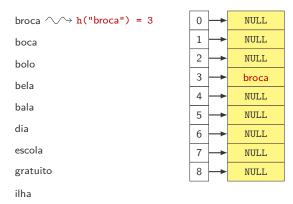
Ideia:





Ideia:

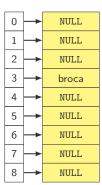




Ideia:



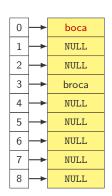




Ideia:



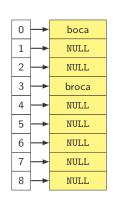




Ideia:

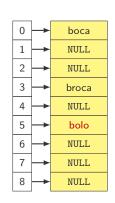


```
broca \rightsquigarrow h("broca") = 3
boca \rightsquigarrow h("boca") = 0
bolo \rightsquigarrow h("bolo") = 5
bela
bala
dia
escola
gratuito
ilha
```



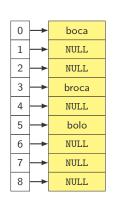
Ideia:





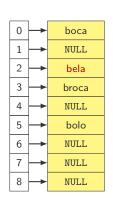
Ideia:





Ideia:

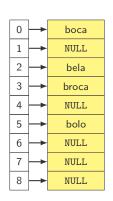




Ideia:



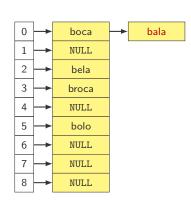




Ideia:

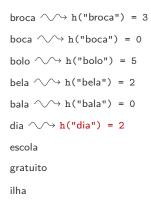


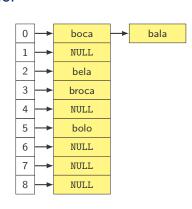




Ideia:



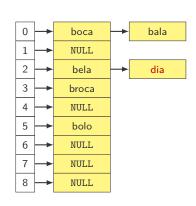




Ideia:



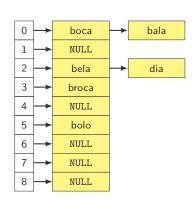




Ideia:



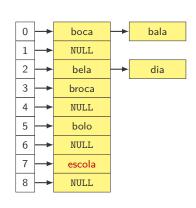




Ideia:

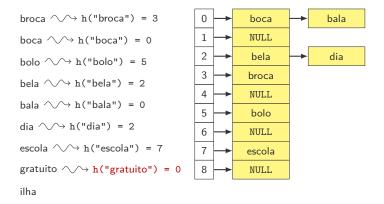






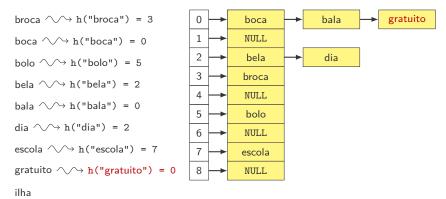
Ideia:





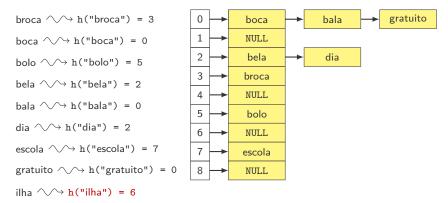
Ideia:





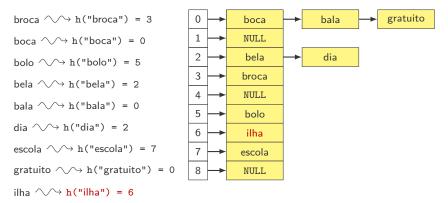
Ideia:





Ideia:





Ideia:



Complexidade do caso médio para tabela hash com encadeamento exterior



• **Definição:** O fator de carga de uma tabela hash é o valor $\alpha = n/M$, onde n é o número de chaves armazenadas e M é o tamanho da tabela.



• **Definição:** O fator de carga de uma tabela hash é o valor $\alpha = n/M$, onde n é o número de chaves armazenadas e M é o tamanho da tabela.



- **Definição:** O fator de carga de uma tabela hash é o valor $\alpha = n/M$, onde n é o número de chaves armazenadas e M é o tamanho da tabela.
- **Definição:** Uma função de hashing h é uniforme se a probabilidade de que h(x) seja igual a k é 1/M para toda chave x e todos os endereços $k \in \{0, \dots, M-1\}.$



- **Definição:** O fator de carga de uma tabela hash é o valor $\alpha = n/M$, onde n é o número de chaves armazenadas e M é o tamanho da tabela.
- **Definição:** Uma função de hashing h é uniforme se a probabilidade de que h(x) seja igual a k é 1/M para toda chave x e todos os endereços $k \in \{0, \dots, M-1\}$.
- **Definição:** Seja A um algoritmo, $\{E_1,\ldots,E_m\}$ o conjunto de todas as entradas possíveis de A. Denote por t_i o número de passos efetuados por A quando a entrada for E_i . Seja p_i a probabilidade de ocorrência da entrada E_i . A complexidade do caso médio de A é dada por

$$\sum_{i=1}^{m} p_i t_i.$$



Complexidade da busca malsucedida

Teorema 1. Numa tabela hash que utiliza função de hashing uniforme e na qual as colisões são tratadas por encadeamento exterior, o número médio de comparações efetuadas numa busca sem sucesso é igual ao fator de carga α .



Demonstração:

 $\bullet\,$ Seja N(T) o número médio de comparações efetuadas em uma busca sem sucesso, numa tabela hash T.



Demonstração:

- Seja ${\cal N}(T)$ o número médio de comparações efetuadas em uma busca sem sucesso, numa tabela hash T.
- Como a função de hashing é uniforme, existe a mesma probabilidade 1/M da busca ser efetuada em qualquer uma das M listas encadeadas. Seja L_i a lista onde a busca se efetua e $|L_i|$ o seu comprimento. Então,

$$N(T) = \frac{1}{M}|L_0| + \frac{1}{M}|L_1| + \dots + \frac{1}{M}|L_{M-1}| = \frac{1}{M}\sum_{i=0}^{M-1}|L_i|.$$



Demonstração:

- Seja ${\cal N}(T)$ o número médio de comparações efetuadas em uma busca sem sucesso, numa tabela hash T.
- Como a função de hashing é uniforme, existe a mesma probabilidade 1/M da busca ser efetuada em qualquer uma das M listas encadeadas. Seja L_i a lista onde a busca se efetua e $|L_i|$ o seu comprimento. Então,

$$N(T) = \frac{1}{M}|L_0| + \frac{1}{M}|L_1| + \dots + \frac{1}{M}|L_{M-1}| = \frac{1}{M}\sum_{i=0}^{M-1}|L_i|.$$

• Como existe um total de n elementos, $\sum_{i=0}^{M-1} |L_i| = n$. Logo,

$$N(T) = \frac{n}{M} = \alpha. \qquad \blacksquare$$



Teorema 2. Numa tabela hash que utiliza função de hashing uniforme e na qual as colisões são tratadas por encadeamento exterior, o número médio de comparações efetuadas numa busca com sucesso é igual a $1+\alpha/2-1/2M$.

Demonstração:



Teorema 2. Numa tabela hash que utiliza função de hashing uniforme e na qual as colisões são tratadas por encadeamento exterior, o número médio de comparações efetuadas numa busca com sucesso é igual a $1+\alpha/2-1/2M$.

Demonstração:

• Seja T uma tabela hash e N(T) o número médio de comparações efetuadas em uma busca com sucesso.



Teorema 2. Numa tabela hash que utiliza função de hashing uniforme e na qual as colisões são tratadas por encadeamento exterior, o número médio de comparações efetuadas numa busca com sucesso é igual a $1+\alpha/2-1/2M$.

Demonstração:

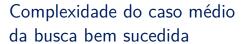
- Seja T uma tabela hash e N(T) o número médio de comparações efetuadas em uma busca com sucesso.
- Sabe-se que a inclusão de cada chave nas listas encadeadas é realizada sempre no final da lista. Supondo a ausência de exclusões nas listas, a posição de cada chave em relação à cabeça da lista se mantém constante.



Teorema 2. Numa tabela hash que utiliza função de hashing uniforme e na qual as colisões são tratadas por encadeamento exterior, o número médio de comparações efetuadas numa busca com sucesso é igual a $1+\alpha/2-1/2M$.

Demonstração:

- Seja T uma tabela hash e N(T) o número médio de comparações efetuadas em uma busca com sucesso.
- Sabe-se que a inclusão de cada chave nas listas encadeadas é realizada sempre no final da lista. Supondo a ausência de exclusões nas listas, a posição de cada chave em relação à cabeça da lista se mantém constante.
- Cada uma das n chaves tem a mesma probabilidade $\frac{1}{n}$ de ser pesquisada.





• Logo, o número médio de comparações para localizar uma chave x, com sucesso, localizada em uma certa lista L_i , é igual ao comprimento médio de L_i na ocasião em que a chave foi inserida em L_i , adicionado de uma unidade (correspondente à comparação final com a própria chave x).



- Logo, o número médio de comparações para localizar uma chave x, com sucesso, localizada em uma certa lista L_i , é igual ao comprimento médio de L_i na ocasião em que a chave foi inserida em L_i , adicionado de uma unidade (correspondente à comparação final com a própria chave x).
- Supondo que x tenha sido a (j+1)-ésima chave a ser incluída, o comprimento médio de L_i é j/M. Logo,



- Logo, o número médio de comparações para localizar uma chave x, com sucesso, localizada em uma certa lista L_i , é igual ao comprimento médio de L_i na ocasião em que a chave foi inserida em L_i , adicionado de uma unidade (correspondente à comparação final com a própria chave x).
- Supondo que x tenha sido a (j+1)-ésima chave a ser incluída, o comprimento médio de L_i é j/M. Logo,

$$N(T) = \frac{1}{n} \left(1 + \frac{0}{M} \right) + \frac{1}{n} \left(1 + \frac{1}{M} \right) + \dots + \frac{1}{n} \left(1 + \frac{n-1}{M} \right)$$
$$= \frac{1}{n} \sum_{j=0}^{n-1} \left(1 + \frac{j}{M} \right) = 1 + \frac{n(n-1)}{2nM} = 1 + \frac{\alpha}{2} - \frac{1}{2M}. \quad \Box$$



• Se o tamanho da tabela for proporcional ao número de elementos, então temos que $n={\cal O}(M).$



- Se o tamanho da tabela for proporcional ao número de elementos, então temos que $n={\cal O}(M).$
- Ou seja, $\alpha = n/M = O(M)/M = O(1)$.



- Se o tamanho da tabela for proporcional ao número de elementos, então temos que $n={\cal O}(M).$
- Ou seja, $\alpha = n/M = O(M)/M = O(1)$.
- Tanto a complexidade média de busca sem sucesso quanto a da busca com sucesso são constantes.



- Se o tamanho da tabela for proporcional ao número de elementos, então temos que $n={\cal O}(M).$
- Ou seja, $\alpha = n/M = O(M)/M = O(1)$.
- Tanto a complexidade média de busca sem sucesso quanto a da busca com sucesso são constantes.

A fim de garantir que as listas não se tornem muito longas, geralmente, mantém-se o invariante

$$\frac{n}{M} \le 1$$

Para isso, pode ser necessário aumentar o tamanho da tabela e reconstruí-la.



Função de hashing

Função de hashing



Definição

Dado um conjunto de chaves K e um inteiro positivo M, uma função de hashing é uma função $h\colon K\to\{0,1,\ldots,M-1\}$ que idealmente satisfaz as seguintes condições:

- produz um número baixo de colisões.
- é facilmente computável.
- é uniforme: a probabilidade de que h(x) seja igual ao índice i dever ser 1/M para todas as chaves $x \in K$ e todos os endereços $i \in \{0,\dots,M-1\}.$



• Na prática, é conveniente implementar uma função de hashing h como a composição de duas funções f e g.



- Na prática, é conveniente implementar uma função de hashing h como a composição de duas funções f e g.
 - A função de codificação f mapeia chaves em inteiros não negativos (hash codes):

$$f\colon K\to \mathbb{Z}_{\geq 0}$$



- Na prática, é conveniente implementar uma função de hashing h como a composição de duas funções f e g.
 - A função de codificação f mapeia chaves em inteiros não negativos (hash codes):

$$f\colon K\to \mathbb{Z}_{\geq 0}$$

o A função de compressão g mapeia hash codes em inteiros no conjunto $\{0,1,\ldots,M-1\}$:

$$g: \mathbb{Z}_{\geq 0} \to \{0, \dots, M-1\}$$



- Na prática, é conveniente implementar uma função de hashing h como a composição de duas funções f e g.
 - A função de codificação f mapeia chaves em inteiros não negativos (hash codes):

$$f\colon K\to \mathbb{Z}_{\geq 0}$$

o A função de compressão g mapeia hash codes em inteiros no conjunto $\{0,1,\ldots,M-1\}$:

$$g: \mathbb{Z}_{>0} \to \{0, \dots, M-1\}$$

• Assim, o valor de hashing h(x) de uma chave $x \in K$ é dado por

$$h(x) = g(f(x)).$$



Primeira componente da função de hashing: Função de codificação



- Strings estão entre os tipos mais comuns de chaves.
- Temos um conjunto de chaves K do tipo string e queremos construir uma função de codificação $f\colon K\to \mathbb{Z}^+$. Vamos supor que o tipo de retorno da função é unsigned int.



- Strings estão entre os tipos mais comuns de chaves.
- Temos um conjunto de chaves K do tipo string e queremos construir uma função de codificação $f\colon K\to \mathbb{Z}^+$. Vamos supor que o tipo de retorno da função é unsigned int.
- Pergunta: Dado um valor do tipo string, como transformá-lo em um valor do tipo unsigned int?



- Strings estão entre os tipos mais comuns de chaves.
- Temos um conjunto de chaves K do tipo string e queremos construir uma função de codificação $f \colon K \to \mathbb{Z}^+$. Vamos supor que o tipo de retorno da função é unsigned int.
- Pergunta: Dado um valor do tipo string, como transformá-lo em um valor do tipo unsigned int?
 - Fato: Uma string é composta por uma cadeia de caracteres. Cada caractere é um inteiro positivo cujo valor é determinado na tabela ASCII.
 - Ideia: Vamos usar o valor ASCII de cada caractere da chave para compor o valor de retorno da função.



• Por exemplo, 'c' = 99, 'a' = 97 e 't' = 116, então essa função hash produziria 99 + 97 + 116 = 312 para a string "cat".

```
1 size_t string_hash_ruim (const char *x, size_t len) {
2    size_t sum = 0;
3    for (size_t i = 0; i < len; ++i)
4        sum += x[i];
5    return sum;
6 }</pre>
```

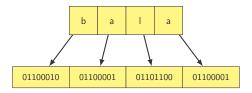


• Por exemplo, 'c' = 99, 'a' = 97 e 't' = 116, então essa função hash produziria 99 + 97 + 116 = 312 para a string "cat".

```
1 size_t string_hash_ruim (const char *x, size_t len) {
2    size_t sum = 0;
3    for (size_t i = 0; i < len; ++i)
4        sum += x[i];
5    return sum;
6 }</pre>
```

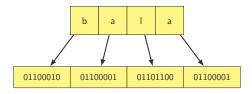
- Essa é uma função de codificação simples, mas não é muito boa. Por exemplo, produz o mesmo valor para "act" como para "cat".
- Uma função de codificação para strings mais sofisticada deve certamente depender de todos os caracteres e da ordem deles.





Como podemos calcular o número x que representa "bala"?

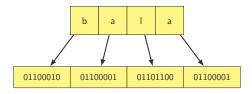




Como podemos calcular o número x que representa "bala"?

•
$$x = \text{'b'} \cdot 127^3 + \text{'a'} \cdot 127^2 + \text{'l'} \cdot 127^1 + \text{'a'} \cdot 127^0$$



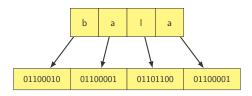


Como podemos calcular o número x que representa "bala"?

•
$$x = \text{'b'} \cdot 127^3 + \text{'a'} \cdot 127^2 + \text{'l'} \cdot 127^1 + \text{'a'} \cdot 127^0$$

que pode ser reescrito como

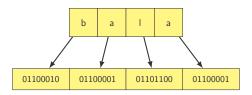




Como podemos calcular o número x que representa "bala"?

- x= 'b' \cdot 127^3+ 'a' \cdot 127^2+ 'l' \cdot 127^1+ 'a' \cdot 127^0 que pode ser reescrito como
- $x = ((('b') \cdot 256 + 'a') \cdot 127 + '1') \cdot 127 + 'a'$





Como podemos calcular o número x que representa "bala"?

•
$$x = \text{'b'} \cdot 127^3 + \text{'a'} \cdot 127^2 + \text{'l'} \cdot 127^1 + \text{'a'} \cdot 127^0$$

que pode ser reescrito como

•
$$x = ((('b') \cdot 256 + 'a') \cdot 127 + '1') \cdot 127 + 'a'$$

Caso o valor de x fique muito grande para caber em um unsigned int, uma operação modulo M é executada internamente, em que M é o valor do maior unsigned int.



```
1 // teste.cpp
2 size_t string_hash ( const char *x, size_t len ) {
3    size_t code = 0, BASE = 127;
4    for (size_t i = 0; i < len; ++i)
5        code = ( code * BASE ) + x[i];
6    return code;
7 }</pre>
```



```
1 // teste.cpp
2 size_t string_hash ( const char *x, size_t len ) {
3    size_t code = 0, BASE = 127;
4    for (size_t i = 0; i < len; ++i)
5       code = ( code * BASE ) + x[i];
6    return code;
7 }</pre>
```

Exemplos com BASE = 127:

- "casa" = 204369132
- "asac" = 200560404
- "saca" = 237141228



- Ideia: trataremos o número de ponto flutuante como uma sequência de bytes. Em C++ um float utiliza 32 bits (4 bytes).
- Como um char é armazenado em 8 bits (1 byte), podemos interpretar um float de 32 bits como um vetor de 4 caracteres.



- Ideia: trataremos o número de ponto flutuante como uma sequência de bytes. Em C++ um float utiliza 32 bits (4 bytes).
- Como um char é armazenado em 8 bits (1 byte), podemos interpretar um float de 32 bits como um vetor de 4 caracteres.
- C++ fornece uma operação de casting reinterpret_cast, para conversão entre tipos não relacionados.
 - Esse casting trata valores como uma sequência de bits e não tenta converter de maneira inteligente o significado de um valor para outro.



```
1 size_t float_hash ( const float& f )
2 {
3     const char *p = reinterpret_cast < const char*>(&f);
4     return string_hash( p, sizeof(f) );
5 }
```



```
1 size_t float_hash ( const float& f )
2 {
3     const char *p = reinterpret_cast < const char *>(&f);
4     return string_hash( p, sizeof(f) );
5 }
```

Exemplos usando hash_float:

- \bullet 23.564 = 34846198
- 87.6 = 105279891
- \bullet 89.096 = 80667418
- \bullet 67.8 = 18446744073498939962
- 3.23413 = 18446744073701287409





```
1 #include <iostream> // generic.cpp
2 #include <string>
3 #include <type_traits>
  template < typename T>
  size_t generic_hash(const T& v) {
      if constexpr (std::is_same < T, std::string >::value) {
          // trata std::string
          return string_hash(v.c_str(), v.size());
      } else {
6
          // trata outros tipos genericamente
           const char* p = reinterpret_cast < const char*>(&v);
          return string_hash(p, sizeof(v));
9
10
11 }
```

 if constexpr é um condicional em tempo de compilação disponível desde o C++17. Ele garante que apenas o ramo relevante do código seja compilado. Ele garante que o primeiro bloco só será compilado se for passado um std::string.



Template de classe std::hash

std::hash



O C++ possui o cabeçalho <functional> no qual está definido o template std::hash da seguinte maneira:
 namespace std {
 template< typename T > class hash;
 }

std::hash



• O C++ possui o cabeçalho <functional> no qual está definido o template std::hash da seguinte maneira:

```
namespace std {
  template< typename T > class hash;
}
```

- Em <functional> há especializações desse template para todos os tipos primitivos, como int, float, double, etc. e também para std::string.
- Em resumo: um objeto da classe std::hash<T> é um objeto sem estado que implementa o operador (). Esse operador recebe como parâmetro um valor do tipo T e retorna seu hash code como size_t.





```
1 #include <iostream> //hash01.cpp
2 #include <string>
3 #include <functional> // para std::hash
4 using namespace std;
5
6 int main () {
7
    string name { "Ana Almeida" };
    hash < string > ff;
8
    cout << name << " = " << ff(name) << endl;</pre>
10
    int i = 24, j = -24;
11
12
    hash<int> hint:
    cout << i << " = " << hint( i ) << endl:
13
    cout << j << " = " << hint( j ) << endl;
14
15
    double d = 23.45, e = 24.35;
16
    cout << d << " = " << hash <double >()( d ) << endl;</pre>
17
     cout << e << " = " << hash <double >()( e ) << endl;</pre>
18
19
    return 0;
20 }
```





Também podemos especializar o template std::hash para definir hash codes para tipos que nós mesmos definirmos.

```
1 #include <iostream> // hash02.cpp
2 #include <string>
3 #include <functional>
4
5 struct Name {
     std::string first;
     std::string last;
8 };
9
  namespace std {
11
   template <>
     class hash < Name > {
12
13
        public:
            size_t operator()( const Name & p ) const {
14
15
               auto n1 = std::hash<string>()(p.first);
               auto n2 = std::hash<string>()(p.last);
16
               return n1 ^ n2; // XOR operation
17
18
19
     }:
20 }
```

std::hash — Tipos definidos pelo usuário (cont.)



```
21 int main () {
    Name p1 {"Ana", "Almeida" };
22
23
    Name p2 {"Aan", "Ameidal" };
24
    size_t key1 = std::hash<Name>()( p1 );
25
    size_t key2 = std::hash<Name>()( p2 );
26
27
28
    std::cout << key1 << std::endl;
    std::cout << key2 << std::endl;
29
30
31
    return 0:
32 }
```





```
1 #include <iostream> // hash03.cpp
2 #include <functional>
4 struct Name {
    std::string first;
5
      std::string last;
  };
0 class hashName {
10 public:
      size_t operator()( const Name &name ) const {
11
12
           auto n1 = std::hash<std::string>()(name.first);
           auto n2 = std::hash<std::string>()(name.last);
13
14
          return n1 ^ n2:
15
16 }:
17
  int main () {
    Name p3 { "Pedro", "Paulo" };
19
    size t key3 = hashName()( p3 );
20
    std::cout << key3 << std::endl;
21
22
    return 0:
23 }
```



Segunda componente da função de hashing: Função de compressão

Recapitulando funções hash...



- Implementamos uma função hash h como a composição de duas funções $f \in g$.
 - A função de codificação f mapeia chaves em inteiros não negativos (hash codes):

$$f\colon K\to \mathbb{Z}^+$$

o A função de compressão g mapeia hash codes em inteiros no conjunto $\{0,1,\ldots,M-1\}$:

$$g: \mathbb{Z}^+ \to \{0, \dots, M-1\}$$

Recapitulando funções hash...



- Implementamos uma função hash h como a composição de duas funções $f \in g$.
 - A função de codificação f mapeia chaves em inteiros não negativos (hash codes):

$$f\colon K\to \mathbb{Z}^+$$

o A função de compressão g mapeia hash codes em inteiros no conjunto $\{0,1,\ldots,M-1\}$:

$$g: \mathbb{Z}^+ \to \{0, \dots, M-1\}$$

Veremos a seguir como implementar uma função de compressão usando o método da divisão.



• **Objetivo:** Construir função g que mapeia qualquer inteiro x não negativo no conjunto $\{0,1,\ldots,M-1\}$



- **Objetivo:** Construir função g que mapeia qualquer inteiro x não negativo no conjunto $\{0,1,\ldots,M-1\}$
- Ideia: usar a função módulo para obter o resto da divisão de x pelo tamanho M da tabela hash.

$$g(x) = x \operatorname{mod} M$$



- **Objetivo:** Construir função g que mapeia qualquer inteiro x não negativo no conjunto $\{0,1,\dots,M-1\}$
- Ideia: usar a função módulo para obter o resto da divisão de x pelo tamanho M da tabela hash.

$$g(x) = x \operatorname{mod} M$$

Exemplo: supondo hash("bala") = 1.650.551.905, temos

$$g(\mathsf{hash("bala")}) = 1.650.551.905 \, \mathbf{mod} \, 1783 = 277$$



- Objetivo: Construir função g que mapeia qualquer inteiro x não negativo no conjunto $\{0,1,\dots,M-1\}$
- Ideia: usar a função módulo para obter o resto da divisão de x pelo tamanho M da tabela hash.

$$g(x) = x \operatorname{mod} M$$

Exemplo: supondo hash("bala") = 1.650.551.905, temos

$$g(\mathsf{hash("bala")}) = 1.650.551.905 \ \mathbf{mod} \ 1783 = 277$$

Escolhendo *M*:

Método da divisão



- Objetivo: Construir função g que mapeia qualquer inteiro x não negativo no conjunto $\{0,1,\dots,M-1\}$
- Ideia: usar a função módulo para obter o resto da divisão de x pelo tamanho M da tabela hash.

$$g(x) = x \operatorname{mod} M$$

Exemplo: supondo hash("bala") = 1.650.551.905, temos

$$g(\mathsf{hash("bala")}) = 1.650.551.905 \, \mathbf{mod} \, 1783 = 277$$

Escolhendo M:

• escolher M como uma potência de 2 não é uma boa ideia:

Método da divisão



- **Objetivo:** Construir função g que mapeia qualquer inteiro x não negativo no conjunto $\{0,1,\ldots,M-1\}$
- Ideia: usar a função módulo para obter o resto da divisão de x pelo tamanho M da tabela hash.

$$g(x) = x \operatorname{mod} M$$

Exemplo: supondo hash("bala") = 1.650.551.905, temos

$$g(\mathsf{hash("bala")}) = 1.650.551.905 \ \mathbf{mod} \ 1783 = 277$$

Escolhendo M:

- escolher M como uma potência de 2 não é uma boa ideia:
 - o considera apenas os bits menos significativos. Exemplo:



• Suponha $M=2^j$ e a chave armazenada numa palavra de memória de 16 bits.



- Suponha $M=2^j$ e a chave armazenada numa palavra de memória de 16 bits.
- Se j=5, a função g(x) produzirá endereços que resultam dos últimos cinco bits da chave, isto é, g(x) não levará nunca em consideração os dígitos mais significativos de x.



- Suponha $M=2^j$ e a chave armazenada numa palavra de memória de 16 bits.
- Se j=5, a função g(x) produzirá endereços que resultam dos últimos cinco bits da chave, isto é, g(x) não levará nunca em consideração os dígitos mais significativos de x.

x	$g(x) = x \mod 32$	binário(x)
16838	6	1000001110 00110
5758	30	10110011 111110
17515	11	1000100011 01011
31051	11	1111001010 01011
5627	27	10101111 11011
23010	2	1011001111 00010
7419	27	11100111 11011
16212	20	111111010 10100
4086	22	11111111 10110



- Suponha $M=2^j$ e a chave armazenada numa palavra de memória de 16 bits.
- Se j=5, a função g(x) produzirá endereços que resultam dos últimos cinco bits da chave, isto é, g(x) não levará nunca em consideração os dígitos mais significativos de x.

x	$g(x) = x \mod 32$	binário(x)
16838	6	1000001110 00110
5758	30	10110011 111110
17515	11	1000100011 01011
31051	11	1111001010 01011
5627	27	10101111 11011
23010	2	1011001111 00010
7419	27	11100111 11011
16212	20	111111010 10100
4086	22	1111111 10110

• Outra escolha ruim: Se M for par, g(x) será par quando x for par e será ímpar caso contrário.

Escolhendo o tamanho M da tabela hash



• Dica: normalmente escolhemos M como um número primo.

Escolhendo o tamanho M da tabela hash



- Dica: normalmente escolhemos M como um número primo.
- ullet Dica do Sedgewick: Escolha uma potência de 2 que esteja próxima do valor desejado de M. Depois, adote para M o número primo que esteja logo abaixo da potência escolhida.

Escolhendo o tamanho M da tabela hash



- Dica: normalmente escolhemos M como um número primo.
- Dica do Sedgewick: Escolha uma potência de 2 que esteja próxima do valor desejado de M. Depois, adote para M o número primo que esteja logo abaixo da potência escolhida.

\boldsymbol{k}	2^k	М
7	128	127
8	256	251
9	512	509
10	1024	1021
11	2048	2039
12	4096	4093
13	8192	8191
14	16384	16381
15	32768	32749
16	65536	65521
17	131072	131071
18	262144	262139

Método da divisão — Implementação



```
1 #include <iostream> // hashFunction02a.cpp
2 #include <iomanip>
3 #include <functional>
4 using namespace std;
5
6 // funcao de codificacao + uncao de compressao
7 size_t hash_code( const float& chave, size_t tableSize )
8 {
      return std::hash<float>()(chave) % tableSize;
10 }
11
12 int main()
13 {
      for(int i = 1; i <= 10; ++i)
14
15
           cout << "hash code(" << setw(3) << right << i * 0.5
16
                <<") = " << hash code(i * 0.5, 251) << endl;
17
18
19 }
```



Implementação da tabela hash com tratamento de colisão por encadeamento exterior

Detalhes de implementação



- Implementaremos a tabela hash como um template de classe chamado
 HashTable. O template terá dois parâmetros: T para a chave e V para o valor associado à chave.
 - Dentro da classe, esses dois valores serão representados como um tipo composto. Para isso, usaremos o tipo std::pair padrão do C++.

Detalhes de implementação



- Implementaremos a tabela hash como um template de classe chamado
 HashTable. O template terá dois parâmetros: T para a chave e V para o valor associado à chave.
 - Dentro da classe, esses dois valores serão representados como um tipo composto. Para isso, usaremos o tipo std::pair padrão do C++.
- A tabela hash com tratamento de colisão por encadeamento exterior consiste em um vetor T[0..M-1] com M slots, onde cada slot é uma lista encadeada contendo as chaves mapeadas naquele slot.
 - Não vamos programar do zero.
 - Vamos usar um std::vector em que cada elemento é uma lista std::list de elementos do tipo std::pair<T,V>

Classe std::pair



 std::pair: Esta classe acopla um par de valores, que podem ser de diferentes tipos (T1 e T2). Está definido no cabeçalho <utility>.

Classe std::pair



- std::pair: Esta classe acopla um par de valores, que podem ser de diferentes tipos (T1 e T2). Está definido no cabeçalho <utility>.
- O primeiro elemento é acessado pelo atributo público 'first' e o segundo elemento é acessado pelo atributo público 'second' e a ordem é fixa (first, second).

Classe std::pair



- std::pair: Esta classe acopla um par de valores, que podem ser de diferentes tipos (T1 e T2). Está definido no cabeçalho <utility>.
- O primeiro elemento é acessado pelo atributo público 'first' e o segundo elemento é acessado pelo atributo público 'second' e a ordem é fixa (first, second).
- std::pair fornece uma maneira de armazenar dois objetos heterogêneos como uma única unidade. O par pode ser atribuído, copiado e comparado.
- Um template de função útil que vamos usar é a função std::make_pair.
 Esta função recebe como argumento dois valores dos tipos T1 e T2 e retorna um std::pair<T1, T2>

Classe std::pair — Exemplo



```
1 // pair.cpp
2 #include <utility> // std::pair
3 #include <iostream> // std::cout
4 using std::cout;
5
6 int main () {
    std::pair <int, int> bar(3,4);
    std::pair <int,int> foo;
8
    foo = std::make_pair (10,20);
10
    cout << "foo: " << foo.first;</pre>
11
    cout << ", " << foo.second << '\n';
12
13
    cout << "bar: " << bar.first;</pre>
14
    cout << ", " << bar.second << '\n':
15
16
17
    return 0;
18 }
```



Outra técnica de tratamento de colisão: Endereçamento aberto





• Existem vários métodos para armazenar N chaves em uma tabela de tamanho M>N, os quais utilizam os slots vazios na própria tabela para resolver as colisões. Esses métodos são chamados endereçamento aberto (open addressing)



- Existem vários métodos para armazenar N chaves em uma tabela de tamanho M>N, os quais utilizam os slots vazios na própria tabela para resolver as colisões. Esses métodos são chamados endereçamento aberto (open addressing)
- Características:
 - evita percorrer usando ponteiros e alocação e desalocação de memória nas inserções e remoções.



- Existem vários métodos para armazenar N chaves em uma tabela de tamanho M>N, os quais utilizam os slots vazios na própria tabela para resolver as colisões. Esses métodos são chamados endereçamento aberto (open addressing)
- Características:
 - evita percorrer usando ponteiros e alocação e desalocação de memória nas inserções e remoções.
 - o se a tabela encher, uma alternativa é criar uma tabela maior
 - e mudar a função de hashing



• Existem vários métodos para armazenar N chaves em uma tabela de tamanho M>N, os quais utilizam os slots vazios na própria tabela para resolver as colisões. Esses métodos são chamados endereçamento aberto (open addressing)

Características:

- evita percorrer usando ponteiros e alocação e desalocação de memória nas inserções e remoções.
- o se a tabela encher, uma alternativa é criar uma tabela maior
 - e mudar a função de hashing
- $\circ~$ No endereçamento aberto, a tabela pode ser preenchida até ficar cheia. Uma consequência disso é que o fator de carga $\alpha=\frac{n}{M}$ nunca é maior do que 1.



 Para executar a inserção usando endereçamento aberto, examinamos sucessivamente a tabela hash (sondamos) até encontrar uma posição vazia na qual inserir a chave.



 Para executar a inserção usando endereçamento aberto, examinamos sucessivamente a tabela hash (sondamos) até encontrar uma posição vazia na qual inserir a chave.



- Para executar a inserção usando endereçamento aberto, examinamos sucessivamente a tabela hash (sondamos) até encontrar uma posição vazia na qual inserir a chave.
- Exemplo: queremos inserir a chave maria neste array. O problema é que não sabemos de antemão quais slots estão vazios. Qual abordagem ingênua poderíamos usar?

0	boca
1	bala
2	bela
3	broca
4	dia
5	bolo
6	
7	
8	



• Ideia: Em vez de seguir a ordem de sondagem $0,1,\ldots,m-1$ (o que exige o tempo de busca O(n)), fazemos com que a sequência de posições sondadas dependa da chave que está sendo inserida.



Para determinar quais serão as posições a sondar, estendemos a <u>função de</u>
 <u>hashing</u> para incluir o número da sondagem (a partir de 0) como uma
 segunda entrada. Assim, a função de hashing se torna:

$$h: U \times \{0, 1, \dots, m-1\} \rightarrow \{0, 1, \dots, m-1\}.$$



Para determinar quais serão as posições a sondar, estendemos a <u>função de</u>
 <u>hashing</u> para incluir o número da sondagem (a partir de 0) como uma
 segunda entrada. Assim, a função de hashing se torna:

$$h: U \times \{0, 1, \dots, m-1\} \rightarrow \{0, 1, \dots, m-1\}.$$

 Com endereçamento aberto, exigimos que, para toda chave k, a sequência de sondagem

$$\langle h(k,0), h(k,1), \dots, h(k,m-1) \rangle$$

seja uma permutação de $\langle 0,1,\dots,m-1\rangle$, de modo que toda posição da tabela hash seja eventualmente considerada uma posição para uma nova chave, à medida que a tabela é preenchida.



Sondagem Linear



broca

boca

bolo

bela

bala

dia

escola

gratuito

ilha

8





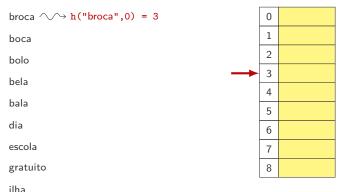
broca $\wedge \rightarrow h("broca",0) = 3$
boca
bolo
bela
bala
dia
escola
gratuito
ilha

0	
1	
2	
3	
4	
5	
6	
7	
8	

Inserindo:

• procuramos posição





- procuramos posição
- se houver espaço, guardamos



broca $\wedge h$ ("broca",0) = 3
boca
bolo
bela
bala
dia
escola
gratuito
ilha

0	
1	
2	
3	broca
4	
5	
6	
7	
8	

- procuramos posição
- se houver espaço, guardamos



0	
1	
2	
3	broca
4	
5	
6	
7	
8	

- procuramos posição
- se houver espaço, guardamos



broca ∕∕→ h("broca",0) = 3	0	
$boca \wedge h("boca",0) = 0$	1	
bolo	2	
bela	3	broca
	4	
bala	5	
dia	6	
escola	7	
gratuito	8	

Inserindo:

• procuramos posição

ilha

• se houver espaço, guardamos



0	boca
1	
2	
3	broca
4	
5	
6	
7	
8	

- procuramos posição
- se houver espaço, guardamos



0	boca
1	
2	
3	broca
4	
5	
6	
7	
8	

- procuramos posição
- se houver espaço, guardamos



broca $\wedge \rightarrow h("broca",0) = 3$	0	boca
boca \rightsquigarrow h("boca",0) = 0	1	
bolo	2	
bela	3	broca
	4	
bala	5	
dia	6	
escola	7	
gratuito	8	

Inserindo:

procuramos posição

ilha

• se houver espaço, guardamos



0	boca
1	
2	
3	broca
4	
5	bolo
6	
7	
8	

- procuramos posição
- se houver espaço, guardamos



0	boca
1	
2	
3	broca
4	
5	bolo
6	
7	
8	

- procuramos posição
- se houver espaço, guardamos



broca $\wedge \rightarrow h("broca",0) = 3$		boca
boca \rightsquigarrow h("boca",0) = 0	1	
bolo	2	
bela	3	broca
	4	
bala	5	bolo
dia	6	
escola	7	
gratuito	8	

Inserindo:

• procuramos posição

ilha

• se houver espaço, guardamos



0	boca
1	
2	bela
3	broca
4	
5	bolo
6	
7	
8	

- procuramos posição
- se houver espaço, guardamos



broca ∕∕→ h("broca",0) = 3	0	boca
boca \rightsquigarrow h("boca",0) = 0	1	
bolo	2	bela
bela $\wedge \rightarrow h("bela",0) = 2$	3	broca
, , , , , ,	4	
bala $\wedge \wedge \rightarrow h("bala", 0) = 0$	5	bolo
dia	6	
escola	7	
gratuito	8	

Inserindo:

• procuramos posição

- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3	0	boca
boca \rightsquigarrow h("boca",0) = 0	1	
bolo	2	bela
bela $\wedge \rightarrow h("bela",0) = 2$	3	broca
, , , , , ,	4	
bala \rightsquigarrow h("bala",0) = 0	5	bolo
dia	6	
escola	7	
gratuito	8	

Inserindo:

procuramos posição

- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3
boca $\rightsquigarrow h("boca",0) = 0$
bolo $\wedge \rightarrow h("bolo",0) = 5$
bela \rightsquigarrow h("bela",0) = 2
bala \rightsquigarrow h("bala",0) = 0
dia
escola
gratuito
ilha

boca
bala
bela
broca
bolo

- procuramos posição
- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3
boca \rightsquigarrow h("boca",0) = 0
bolo $\wedge \rightarrow h("bolo",0) = 5$
bela \rightsquigarrow h("bela",0) = 2
bala \rightsquigarrow h("bala",0) = 0
dia
escola
gratuito
ilha

0	boca
1	bala
2	bela
3	broca
4	
5	bolo
6	
7	
8	

- procuramos posição
- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3
boca $\wedge \rightarrow h("boca",0) = 0$
bolo \rightsquigarrow h("bolo",0) = 5
bela \rightsquigarrow h("bela",0) = 2
bala \rightsquigarrow h("bala",0) = 0
$dia \sim h("dia",0) = 2$
escola
gratuito
ilha

0	boca
1	bala
2	bela
3	broca
4	
5	bolo
6	
7	
8	

- procuramos posição
- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3
boca $\wedge \rightarrow h("boca",0) = 0$
bolo \rightsquigarrow h("bolo",0) = 5
bela \rightsquigarrow h("bela",0) = 2
bala \rightsquigarrow h("bala",0) = 0
$dia \sim h("dia",0) = 2$
escola
gratuito
ilha

0	boca
1	bala
2	bela
3	broca
4	
5	bolo
6	
7	
8	

- procuramos posição
- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3	0	boca
boca $\wedge \rightarrow h("boca",0) = 0$	1	bala
bolo	2	bela
bela \rightsquigarrow h("bela".0) = 2	3	broca
, , , , , ,	4	
bala $\wedge \rightarrow h("bala",0) = 0$	5	bolo
dia	6	
escola	7	
gratuito	8	

Inserindo:

• procuramos posição

- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3	0	boca
boca $\sim h("boca",0) = 0$	1	bala
bolo	2	bela
bela	3	broca
, ,	4	
bala $\wedge \wedge \rightarrow h("bala", 0) = 0$	5	bolo
dia ∕∕→ h("dia",0) = 2	6	
escola	7	
gratuito	8	

Inserindo:

procuramos posição

- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3	0	boca
boca $\wedge \rightarrow h("boca",0) = 0$	1	bala
bolo	2	bela
bela \rightsquigarrow h("bela",0) = 2	3	broca
→	4	
bala $\wedge \rightarrow h("bala",0) = 0$	5	bolo
dia \square h("dia",0) = 2	6	
escola	7	
gratuito	8	

Inserindo:

procuramos posição

- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3
boca $\rightsquigarrow h("boca",0) = 0$
bolo $\wedge \rightarrow h("bolo",0) = 5$
bela \rightsquigarrow h("bela",0) = 2
bala \rightsquigarrow h("bala",0) = 0
dia \rightsquigarrow h("dia",0) = 2
escola
gratuito
ilha

0	boca
1	bala
2	bela
3	broca
4	dia
5	bolo
6	
7	
8	

- procuramos posição
- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca $\wedge \rightarrow h("broca",0) = 3$
$boca \rightsquigarrow h("boca",0) = 0$
bolo \rightsquigarrow h("bolo",0) = 5
bela \rightsquigarrow h("bela",0) = 2
bala \rightsquigarrow h("bala",0) = 0
dia ∕√→ h("dia",0) = 2
escola $\wedge \rightarrow h("escola",0) = 7$
gratuito
ilha

0	boca
1	bala
2	bela
3	broca
4	dia
5	bolo
6	
7	
8	

- procuramos posição
- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca $\wedge \rightarrow h("broca",0) = 3$	0	boca
boca \rightsquigarrow h("boca",0) = 0	1	bala
bolo	2	bela
bela $\wedge \rightarrow h("bela",0) = 2$	3	broca
, , , , , , , , , , , , , , , , , , , ,	4	dia
bala $\wedge \wedge \rightarrow h("bala", 0) = 0$	5	bolo
dia ∕∕→ h("dia",0) = 2	6	
escola $\wedge h$ ("escola",0) = 7	7	
gratuito	8	

Inserindo:

procuramos posição

- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3
boca $\wedge \rightarrow h("boca",0) = 0$
bolo \rightsquigarrow h("bolo",0) = 5
bela \rightsquigarrow h("bela",0) = 2
bala \rightsquigarrow h("bala",0) = 0
dia ∕√→ h("dia",0) = 2
escola \rightsquigarrow h("escola",0) = 7
gratuito
ilha

0	boca
1	bala
2	bela
3	broca
4	dia
5	bolo
6	
7	escola
8	

- procuramos posição
- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3
boca \rightsquigarrow h("boca",0) = 0
bolo $\wedge \rightarrow h("bolo",0) = 5$
bela \rightsquigarrow h("bela",0) = 2
bala \rightsquigarrow h("bala",0) = 0
dia ∕∕→ h("dia",0) = 2
escola $\wedge \rightarrow h("escola",0) = 7$
gratuito $\rightsquigarrow h("gratuito",0) = 0$
ilha

0	boca
1	bala
2	bela
3	broca
4	dia
5	bolo
6	
7	escola
8	

- procuramos posição
- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca √→ h("broca",0) = 3	0	boca
boca $\sim h("boca",0) = 0$	1	bala
bolo	2	bela
bela ∕	3	broca
, , , , , , , , , , , , , , , , , , , ,	4	dia
bala $\wedge \wedge \rightarrow h("bala", 0) = 0$	5	bolo
dia ∕∕→ h("dia",0) = 2	6	
escola $\wedge \rightarrow h("escola",0) = 7$	7	escola
gratuito $\wedge \rightarrow h("gratuito", 0) = 0$	8	

Inserindo:

procuramos posição

- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca $\wedge \rightarrow h("broca",0) = 3$	0	boca
boca	1	bala
bolo	2	bela
bela ∕ → h("bela",0) = 2	3	broca
•	4	dia
bala $\wedge \rightarrow h("bala",0) = 0$	5	bolo
dia ∕∕→ h("dia",0) = 2	6	
escola $\wedge \rightarrow h("escola",0) = 7$	7	escola
gratuito $\wedge \rightarrow h("gratuito", 0) = 0$	8	

Inserindo:

procuramos posição

- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3	0	boca
boca \rightsquigarrow h("boca",0) = 0	1	bala
bolo	2	bela
bela ∕	3	broca
, , , , , ,	4	dia
bala ∕∕→ h("bala",0) = 0	5	bolo
dia ∕∕→ h("dia",0) = 2	6	
escola $\wedge \rightarrow h("escola",0) = 7$	7	escola
gratuito $\wedge \rightarrow h("gratuito", 0) = 0$	8	

Inserindo:

• procuramos posição

- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3	0	boca
boca \rightsquigarrow h("boca",0) = 0	1	bala
bolo	2	bela
bela	3	broca
, , , , , ,	4	dia
bala \rightsquigarrow h("bala",0) = 0	5	bolo
dia \longrightarrow h("dia",0) = 2	6	
escola \rightsquigarrow h("escola",0) = 7	7	escola
gratuito $\sim h("gratuito", 0) = 0$	8	

Inserindo:

• procuramos posição

- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3	0	boca
boca \rightsquigarrow h("boca",0) = 0	1	bala
bolo	2	bela
bela $\wedge \rightarrow h("bela",0) = 2$	3	broca
→	4	dia
bala \rightsquigarrow h("bala",0) = 0	5	bolo
dia ∕∕→ h("dia",0) = 2	6	
escola $\wedge \rightarrow h("escola",0) = 7$	7	escola
gratuito \rightsquigarrow h("gratuito",0) = 0	8	
ilha		

- procuramos posição
- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3	0	boca
boca \rightsquigarrow h("boca",0) = 0	1	bala
bolo	2	bela
bela $\wedge \rightarrow h("bela",0) = 2$	3	broca
, , , , , ,	4	dia
bala $\wedge \rightarrow h("bala", 0) = 0$	5	bolo
dia ∕∕→ h("dia",0) = 2	6	
escola $\wedge \rightarrow h("escola",0) = 7$	7	escola
gratuito $\sim h("gratuito", 0) = 0$	8	

Inserindo:

procuramos posição

- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3	0	boca
boca \rightsquigarrow h("boca",0) = 0	1	bala
bolo	2	bela
bela $\wedge \rightarrow h("bela",0) = 2$	3	broca
, , , , , , , , , , , , , , , , , , , ,	4	dia
bala $\wedge \wedge \rightarrow h("bala", 0) = 0$	5	bolo
dia ∕∕→ h("dia",0) = 2	6	
escola $\wedge \rightarrow h("escola",0) = 7$	7	escola
gratuito $\sim h("gratuito", 0) = 0$	8	

Inserindo:

procuramos posição

- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3
boca \rightsquigarrow h("boca",0) = 0
bolo $\wedge \rightarrow h("bolo",0) = 5$
bela \rightsquigarrow h("bela",0) = 2
bala \rightsquigarrow h("bala",0) = 0
dia ∕∕→ h("dia",0) = 2
escola $\wedge \rightarrow h("escola",0) = 7$
gratuito $\rightsquigarrow h("gratuito",0) = 0$
ilha

0	boca
1	bala
2	bela
3	broca
4	dia
5	bolo
6	gratuito
7	escola
8	

- procuramos posição
- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3
boca \rightsquigarrow h("boca",0) = 0
bolo $\wedge \rightarrow h("bolo",0) = 5$
bela $\wedge \rightarrow h("bela",0) = 2$
bala $\wedge \rightarrow h("bala",0) = 0$
dia ∕ → h("dia",0) = 2
escola $\wedge \rightarrow h("escola",0) = 7$
gratuito \rightsquigarrow h("gratuito",0) = 0
ilha \rightsquigarrow h("ilha",0) = 6

0	boca
1	bala
2	bela
3	broca
4	dia
5	bolo
6	gratuito
7	escola
8	

- procuramos posição
- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3	0	boca
boca \rightsquigarrow h("boca",0) = 0	1	bala
bolo	2	bela
bela $\wedge \wedge \rightarrow h("bela",0) = 2$	3	broca
bala \square h("bala",0) = 0	4	dia
, ,	5	bolo
dia ∕ → h("dia",0) = 2	6	gratuito
escola $\wedge \rightarrow$ h("escola",0) = 7	7	escola
gratuito \rightsquigarrow h("gratuito",0) = 0	8	

Inserindo:

- procuramos posição
- se houver espaço, guardamos

ilha $\wedge \wedge \rightarrow h("ilha", 0) = 6$

ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca $\wedge \rightarrow h("broca",0) = 3$	0	boca
boca \rightsquigarrow h("boca",0) = 0	1	bala
bolo	2	bela
hela $\wedge \wedge \rightarrow h("bela",0) = 2$	3	broca
	4	dia
bala $\wedge \rightarrow h("bala",0) = 0$	5	bolo
dia ∕ → h("dia",0) = 2	6	gratuito
escola $\wedge \rightarrow h("escola",0) = 7$	7	escola
gratuito $\wedge \rightarrow h("gratuito",0) = 0$	8	

Inserindo:

- procuramos posição
- se houver espaço, guardamos

ilha $\wedge \wedge \rightarrow h("ilha", 0) = 6$

ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3	0	boca
boca \rightsquigarrow h("boca",0) = 0	1	bala
bolo	2	bela
bela $\wedge \wedge \rightarrow h("bela",0) = 2$	3	broca
$bala \land \land h("bala", 0) = 0$	4	dia
	5	bolo
dia ∕ → h("dia",0) = 2	6	gratuito
escola $\wedge \rightarrow h("escola",0) = 7$	7	escola
gratuito \sim h("gratuito",0) = 0	8	

Inserindo:

- procuramos posição
- se houver espaço, guardamos

ilha $\wedge \wedge \rightarrow h("ilha", 0) = 6$

ullet se não houver espaço, procuramos a próxima posição livre (módulo M)



broca \rightsquigarrow h("broca",0) = 3
boca \rightsquigarrow h("boca",0) = 0
bolo \rightsquigarrow h("bolo",0) = 5
bela \rightsquigarrow h("bela",0) = 2
bala \rightsquigarrow h("bala",0) = 0
dia ∕∕→ h("dia",0) = 2
escola $\wedge \rightarrow h("escola",0) = 7$
gratuito $\wedge \rightarrow h("gratuito",0) = 0$
ilha \rightsquigarrow h("ilha",0) = 6

0	boca
1	bala
2	bela
3	broca
4	dia
5	bolo
6	gratuito
7	escola
8	ilha

- procuramos posição
- se houver espaço, guardamos
- ullet se não houver espaço, procuramos a próxima posição livre (módulo M)

Sondagem linear (linear probing)



• Dada uma função hash comum $h'\colon U\to\{0,1,\dots,m-1\}$, à qual nos referimos como uma função hash auxiliar, o método de sondagem linear usa a função hash

$$h(k,i) = (h'(k) + i) \mod m$$
, para $i = 0, 1, ..., m - 1$.

Sondagem linear (linear probing)



• Dada uma função hash comum $h'\colon U\to\{0,1,\dots,m-1\}$, à qual nos referimos como uma função hash auxiliar, o método de sondagem linear usa a função hash

$$h(k,i) = (h'(k) + i) \mod m$$
, para $i = 0, 1, ..., m - 1$.

- Obs.1: Note que $\langle h(k,0),h(k,1),\dots,h(k,m-1)\rangle$ é uma permutação de $\langle 0,1,\dots,m-1\rangle.$
- Obs.2: Como a sondagem inicial determina toda a sequência de sondagem, há somente m sequências de sondagem distintas.

Sondagem linear (linear probing)



• Dada uma função hash comum $h'\colon U\to\{0,1,\dots,m-1\}$, à qual nos referimos como uma função hash auxiliar, o método de sondagem linear usa a função hash

$$h(k,i) = (h'(k) + i) \mod m$$
, para $i = 0, 1, ..., m - 1$.

- Obs.1: Note que $\langle h(k,0), h(k,1), \dots, h(k,m-1) \rangle$ é uma permutação de $\langle 0,1,\dots,m-1 \rangle$.
- Obs.2: Como a sondagem inicial determina toda a sequência de sondagem, há somente m sequências de sondagem distintas.
- A sondagem linear sofre de um problema conhecido como agrupamento primário (primary clustering): longas sequências de posições ocupadas se acumulam, aumentando o tempo médio de busca.



Implementação da Tabela

Endereçamento aberto — Implementação da Tabela



• Como os elementos serão agora guardados na própria tabela, precisamos saber quando uma posição da tabela está vazia (disponível) e quando ela contém um elemento válido (não está disponível).

Endereçamento aberto — Implementação da Tabela PEDERAL DOCEARA

- Como os elementos serão agora guardados na própria tabela, precisamos saber quando uma posição da tabela está vazia (disponível) e quando ela contém um elemento válido (não está disponível).
- Para isso, podemos supor que cada slot j da tabela T[0..M-1] contém um objeto T[j] que possui os seguintes campos:
 - status: indica se o slot está ou não disponível. Pode assumir os valores EMPTY, ACTIVE e DELETED.
 - o key: guarda a chave.
 - o value: guarda o valor associado à chave.

Endereçamento aberto — Implementação da Tabela...



• No início, quando a tabela é criada, o campo status de todos os objetos são EMPTY.

Endereçamento aberto — Implementação da Tabela Medida Coccar

- No início, quando a tabela é criada, o campo status de todos os objetos são EMPTY.
- À medida que pares chave-valor são inseridos ou removidos, esses campos vão recebendo os valores ACTIVE ou DELETED, respectivamente, e nunca mais voltam a ser EMPTY enquanto a tabela se manter do mesmo tamanho.

Endereçamento aberto — Implementação da Tabela PROPERTIDA DE LA TABELA DEL TABELA DE LA TABELA D

- No início, quando a tabela é criada, o campo status de todos os objetos são EMPTY.
- Á medida que pares chave-valor são inseridos ou removidos, esses campos vão recebendo os valores ACTIVE ou DELETED, respectivamente, e nunca mais voltam a ser EMPTY enquanto a tabela se manter do mesmo tamanho.
- Quando a tabela encher, uma operação de rehashing é executada, uma nova tabela maior é criada (com todos os status EMPTY) e os elementos da tabela antiga são re-inseridos na tabela nova.

Endereçamento aberto — Inserção



- O procedimento Hash-Insert tem como entrada uma tabela hash T[0..M-1] de tamanho M, uma chave k e seu valor v associado.
- Devolve o índice de T onde a chave k é armazenada ou sinaliza um erro porque a tabela já está cheia.

Endereçamento aberto — Inserção



- O procedimento Hash-Insert tem como entrada uma tabela hash T[0..M-1] de tamanho M, uma chave k e seu valor v associado.
- Devolve o índice de T onde a chave k é armazenada ou sinaliza um erro porque a tabela já está cheia.

```
1 HASH-INSERT (T, k, v)
      i = 0
      dο
           j = h(k,i)
           if(T[j].status == ACTIVE and T[j].key == k)
               break
           if( T[j].status != ACTIVE )
               T[j].key = k
               T[i].value = v
               T[j].status = ACTIVE
10
               return i
11
           i = i + 1
12
      while ( i < M )
13
      error "hash table overflow or repeated key"
14
```

Busca em endereçamento aberto



Como fazer uma busca com endereçamento aberto?

Busca em endereçamento aberto



Como fazer uma busca com endereçamento aberto?

- Basta simular a inserção:
 - Calcule a função de hashing
 - o Percorra a tabela em sequência procurando pela chave
 - Se encontrar a chave, devolva o valor associado à chave
 - Se encontrar um slot vazio (status == EMPTY), então lance uma exceção, indicando que não encontrou

Busca em tabela de endereçamento aberto



Algoritmo:

Remoção em endereçamento aberto



- Ideia: o campo status de cada objeto da tabela suporta um valor chamado DELETED indicando que aquele elemento foi removido.
- Assim, para remover o elemento da tabela, basta atribuir o valor DELETED ao campo status do objeto.

Remoção em endereçamento aberto



Algoritmo:





É semelhante à sondagem linear, só que agora nós usamos duas funções de hashing comuns, denominadas $hash_1$ e a $hash_2$:



É semelhante à sondagem linear, só que agora nós usamos duas funções de hashing comuns, denominadas $hash_1$ e a $hash_2$:

• Quando detectamos conflito, ao invés de dar um pulo de 1, damos um pulo h(k,i) calculado a partir de uma segunda função de hashing. Isto é,

$$h(k,i) = (hash_1(k) + i \cdot hash_2(k)) \mod M$$



É semelhante à sondagem linear, só que agora nós usamos duas funções de hashing comuns, denominadas $hash_1$ e a $hash_2$:

• Quando detectamos conflito, ao invés de dar um pulo de 1, damos um pulo h(k,i) calculado a partir de uma segunda função de hashing. Isto é,

$$h(k,i) = (hash_1(k) + i \cdot hash_2(k)) \mod M$$

Sequência de sondagem:

- $h(k,0) = hash_1(k) \bmod M$
- $h(k,1) = (hash_1(k) + hash_2(k)) \mod M$
- $h(k,2) = (hash_1(k) + 2 \cdot hash_2(k)) \mod M$
- . . .

Cuidados a se tomar com o hashing duplo



Dada a função de hashing duplo:

$$h(k,i) = (hash_1(k) + i \cdot hash_2(k)) \mod M$$

- $hash_2(k)$ nunca pode ser zero
- $hash_2(k)$ precisa ser co-primo com M.
 - o garante que toda a tabela seja pesquisada.
 - $\circ\:$ dois números a e b são co-primos se não têm nenhum divisor em comum além de 1

Cuidados a se tomar com o hashing duplo (cont.)



$$h(k,i) = (hash_1(k) + i \cdot hash_2(k)) \mod M$$

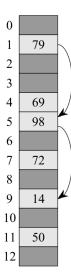
Exemplos de escolhas para M e $hash_2$:

- (i) Escolha M como uma potência de 2 e faça que $hash_2(k)$ seja sempre ímpar
- (ii) Escolha M como um número primo e faça com que $hash_2(k) < M$. Por exemplo, escolhendo M primo, podemos fazer
 - $\circ hash_1(k) = k \mod M$
 - $\circ \ hash_2(k) = 1 + (k \mod m')$

onde m^\prime é ligeiramente menor que M (por exemplo M-1 ou um primo menor que M)

Hashing duplo — Exemplo



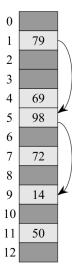


$$h(k,i) = (hash_1(k) + i \cdot hash_2(k)) \mod M$$

• Tabela hash de tamanho M=13 com $hash_1(k)=k \bmod 13 \ {\rm e}$ $hash_2(k)=1+(k \bmod 11).$

Hashing duplo — Exemplo





$$h(k,i) = (hash_1(k) + i \cdot hash_2(k)) \mod M$$

- Tabela hash de tamanho M=13 com $hash_1(k)=k \bmod 13$ e $hash_2(k)=1+(k \bmod 11).$
- Como $14 \equiv 1 \pmod{13}$ e $14 \equiv 3 \pmod{11}$, inserimos a chave 14 na posição vazia 9, após examinar as posições 1 e 5 e verificarmos que elas já estão ocupadas.



Sondagem linear - tempo de busca médio

n/M	1/2	2/3	3/4	9/10
com sucesso	1.5	2.0	3.0	5.5
sem sucesso	2.5	5.0	8.5	55.5

¹Baseado em Sedgewick, R. Algorithms in C, third edition, Addison-Wesley. 1998.



Sondagem linear - tempo de busca médio

n/M	1/2	2/3	3/4	9/10
com sucesso	1.5	2.0	3.0	5.5
sem sucesso	2.5	5.0	8.5	55.5

Hashing duplo - tempo de busca médio

$$\begin{array}{c|ccccc} n/M & 1/2 & 2/3 & 3/4 & 9/10 \\ \hline \text{com sucesso} & 1.4 & 1.6 & 1.8 & 2.6 \\ \text{sem sucesso} & 1.5 & 2.0 & 3.0 & 5.5 \\ \hline \end{array}$$

¹Baseado em Sedgewick, R. Algorithms in C, third edition, Addison-Wesley. 1998.



Sondagem linear - tempo de busca médio

n/M	1/2	2/3	3/4	9/10
com sucesso	1.5	2.0	3.0	5.5
sem sucesso	2.5	5.0	8.5	55.5

Hashing duplo - tempo de busca médio

De qualquer forma, é muito importante não deixar a tabela encher muito:

¹Baseado em Sedgewick, R. Algorithms in C, third edition, Addison-Wesley. 1998.



Sondagem linear - tempo de busca médio

n/M	1/2	2/3	3/4	9/10
com sucesso	1.5	2.0	3.0	5.5
sem sucesso	2.5	5.0	8.5	55.5

Hashing duplo - tempo de busca médio

n/M	1/2	2/3	3/4	9/10
com sucesso	1.4	1.6	1.8	2.6
sem sucesso	1.5	2.0	3.0	5.5

De qualquer forma, é muito importante não deixar a tabela encher muito:

• Você pode aumentar o tamanho da tabela dinamicamente

¹Baseado em Sedgewick, R. Algorithms in C, third edition, Addison-Wesley. 1998.



Sondagem linear - tempo de busca médio

n/M	1/2	2/3	3/4	9/10
com sucesso	1.5	2.0	3.0	5.5
sem sucesso	2.5	5.0	8.5	55.5

Hashing duplo - tempo de busca médio

n/M	1/2	2/3	3/4	9/10
com sucesso	1.4	1.6	1.8	2.6
sem sucesso	1.5	2.0	3.0	5.5

De qualquer forma, é muito importante não deixar a tabela encher muito:

- Você pode aumentar o tamanho da tabela dinamicamente
- Porém, precisa fazer um rehash de cada elemento para a nova tabela

¹Baseado em Sedgewick, R. Algorithms in C, third edition, Addison-Wesley. 1998.



Hashing é uma boa estrutura de dados para



Hashing é uma boa estrutura de dados para

• inserir, remover e buscar dados pela sua chave rapidamente



Hashing é uma boa estrutura de dados para

- inserir, remover e buscar dados pela sua chave rapidamente
- com uma boa função de hashing, essas operações levam tempo O(1)



Hashing é uma boa estrutura de dados para

- inserir, remover e buscar dados pela sua chave rapidamente
- com uma boa função de hashing, essas operações levam tempo O(1)
- mas não é boa se quisermos fazer operação relacionadas a ordem das chaves



Hashing é uma boa estrutura de dados para

- inserir, remover e buscar dados pela sua chave rapidamente
- com uma boa função de hashing, essas operações levam tempo O(1)
- mas não é boa se quisermos fazer operação relacionadas a ordem das chaves



Hashing é uma boa estrutura de dados para

- inserir, remover e buscar dados pela sua chave rapidamente
- com uma boa função de hashing, essas operações levam tempo O(1)
- mas não é boa se quisermos fazer operação relacionadas a ordem das chaves

Escolhendo a implementação:

• Sondagem linear é o mais rápido se a tabela for esparsa



Hashing é uma boa estrutura de dados para

- inserir, remover e buscar dados pela sua chave rapidamente
- com uma boa função de hashing, essas operações levam tempo O(1)
- mas não é boa se quisermos fazer operação relacionadas a ordem das chaves

- Sondagem linear é o mais rápido se a tabela for esparsa
- Hashing duplo usa melhor a memória



Hashing é uma boa estrutura de dados para

- inserir, remover e buscar dados pela sua chave rapidamente
- com uma boa função de hashing, essas operações levam tempo O(1)
- mas não é boa se quisermos fazer operação relacionadas a ordem das chaves

- Sondagem linear é o mais rápido se a tabela for esparsa
- Hashing duplo usa melhor a memória
 - o mas gasta mais tempo para computar a segunda função de hash



Hashing é uma boa estrutura de dados para

- inserir, remover e buscar dados pela sua chave rapidamente
- com uma boa função de hashing, essas operações levam tempo O(1)
- mas não é boa se quisermos fazer operação relacionadas a ordem das chaves

- Sondagem linear é o mais rápido se a tabela for esparsa
- Hashing duplo usa melhor a memória
 - o mas gasta mais tempo para computar a segunda função de hash
- Encadeamento exterior é mais fácil de implementar



Hashing é uma boa estrutura de dados para

- inserir, remover e buscar dados pela sua chave rapidamente
- com uma boa função de hashing, essas operações levam tempo O(1)
- mas não é boa se quisermos fazer operação relacionadas a ordem das chaves

- Sondagem linear é o mais rápido se a tabela for esparsa
- Hashing duplo usa melhor a memória
 - o mas gasta mais tempo para computar a segunda função de hash
- Encadeamento exterior é mais fácil de implementar
 - Usa memória a mais para os ponteiros



FIM